

Diplomado en Ciencia de Datos y Análisis Avanzado

Unidad 5: Modelado Predictivo I-Regresión y Clasificación

Proyecto Práctico Predicción de Abandono de Clientes



Objetivos

- **Aplicar** los conceptos fundamentales de los modelos de clasificación (Regresión Logística, kNN, Naive Bayes) en un problema de negocio real.
- **Incorporar** un flujo de trabajo completo de Machine Learning, incluyendo la exploración de datos, el preprocesamiento, el entrenamiento y la evaluación de modelos.
- **Analizar** y comparar el rendimiento de diferentes algoritmos de clasificación utilizando métricas apropiadas como ROC AUC.
- **Desarrollar** habilidades de trabajo en equipo, colaboración y comunicación técnica a través de un proyecto práctico.



Consigna

Se les solicita a los equipos desarrollar un proyecto de clasificación para predecir el abandono de clientes de una empresa de telecomunicaciones. Para ello, deberán seguir los siguientes pasos:

1. **Equipos:** Trabajar en equipo de acuerdo a los grupos que ya están preestablecidos.
2. **Descargar los Materiales:** Descargar los archivos de datos (train.csv, test.csv) y la plantilla de trabajo (Plantilla_de_Jupyter_Notebook_para_el_Proyecto.ipynb).
Link de los Archivos: [Archivos Trabajo Práctico](#)
3. **Análisis y Modelado:** Utilizando la plantilla proporcionada como referencia, realizar el análisis exploratorio de datos, el preprocesamiento y el entrenamiento/evaluación de los modelos de Regresión Logística, kNN y Naive Bayes.
4. **Elaborar el Informe Final:** Completar el cuaderno Jupyter Notebook (.ipynb) documentando todo el proceso, análisis, código, decisiones tomadas y conclusiones del equipo.
5. **Realizar la Entrega Final:** Subir el cuaderno a esta tarea en Moodle antes de la fecha límite.

Fecha límite de entrega:

La fecha de entrega será hasta el 08 de agosto de 2026

Criterios de evaluación

La calificación final del proyecto se calculará en base a la siguiente ponderación:

- **100% - Informe de Resultados (Jupyter Notebook):**
 - **Análisis Exploratorio de Datos (20%):** Profundidad del análisis, calidad y pertinencia de las visualizaciones.
 - **Preprocesamiento (30%):** Correcta implementación de la limpieza, codificación y escalado de datos. Justificación de las decisiones tomadas.
 - **Modelado y Evaluación (30%):** Implementación correcta de los tres modelos solicitados. Rigurosidad en la evaluación local y comparación de los modelos.
 - **Calidad General del Notebook (20%):** Claridad del código, calidad de los comentarios, estructura del informe, reproducibilidad y conclusiones.



Bibliografía utilizada y sugerida

- **Documentación de Scikit-learn:**
 - Logistic Regression
 - KNeighbors Classifier
 - Gaussian Naive Bayes
- **Libros y Recursos Adicionales:**
 - Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow. 2nd ed. O'Reilly Media.
 - Müller, A. C., & Guido, S. (2016). Introduction to Machine Learning with Python: A Guide for Data Scientists. O'Reilly Media.